

Dokumentacja Aplikacji Indeksowania Stron

Spis Treści

Wprowadzenie	1
Main.Py	2
Data_download.py	5
Data_pars.py	7
Data_display.py	8
Źródła użyte w trakcie prac nad projektem:	9

Wprowadzenie

Aplikacja została napisana wykorzystując język Python w wersji 3.12.0. W folderze aplikacji znajdują się następujące pliki:

Main.Py - Główny plik odpowiedzialny za podstawowe okno aplikacji wraz z całym jego wyglądem i parametrami okna.

Download_data.json - Plik JSON będący domyślnie pustym, zapisywane są w nim konkretne pliki pobrane przez funkcję zawartą w Data_download.py. Plik można wyczyścić ręcznie lub jest automatycznie czyszczony w momencie zamykania aplikacji.

Data_download.py - W tym pliku znajduje się funkcja odpowiedzialna za pobranie konkretnych plików z strony, a następnie umieszczenie ich w pliku Download_data.json.

Data_pars.py - Plik, w którym znajduje się funkcja odpowiedzialna za analizowanie i porządkowanie danych zawartych w pliku Download_data.json.

Data_display.py - Plik z funkcją odpowiedzialną za zebranie uporządkowanych danych i wyświetlenie ich w nowym oknie aplikacji.

Aplikacja została utrzymana w kolorystyce podobnej do aplikacji wcześniej opisywanej w ramach tego samego zadania, czyli biała z szarymi napisami i pomarańczowe akcenty.

Main.Py

Główny plik aplikacji mający w sobie zaimportowane Biblioteki i pliki z funkcjami oraz danymi takimi jak:

- Tkinter
- Data_download
- Data_pars
- Data_display

Cały kod podzielony jest na osiem odpowiednio podpisanych regionów w celu łatwiejszego poruszania się po nim i odczytu fizycznego.

Podstawowa zmienna aplikacji nazywa się “app” i pod nią są podpisane ustawienia takie jak:

- Stały rozmiar okna aplikacji
- Tytuł Okna
- Rozmiar aplikacji podany w pikselach
- Tło głównego okna

Po uruchomieniu aplikacji ukazuje nam się prostokątne okno z tytułem “Prosta Aplikacja Indeksowania Stron” podpisana w kodzie pod zmienną “title_label” zawierającą parametry kolorystyczne i wyglądu tytułu. Ustawienie elementów okna głównego zostało oparte o siatkę (“grid”) i ustawione w jednej kolumnie (“column”) z podziałem na osobne rzędy (“row”).

W następnej sekcji umieszczone są funkcje odpowiedzialne za pokazywanie i ukrywanie komunikatów w aplikacji dotyczących wypełnionych przez przyciski funkcji, wraz z wywoływaniem z innych plików funkcji odpowiedzialnych za adekwatne działania.

Następne 4 regiony poświęcone są przyciskom odpowiedzialnym za wykonywanie wyżej wymienionych funkcji za pomocą parametru “command” dodanego do parametrów przycisku, gdzie:

“Pobieranie Danych” aktywuje funkcję “dwn_show” odpowiedzialną za wykonanie funkcji “data_scrap” z pliku “Data_download”, a także wyświetlenie napisu “Operacja Przeprowadzana w nowym oknie” przy czym ukrywa komunikaty podpisane pod dwa następne przyciski.

“Parsowanie Danych” ma przypisaną funkcję “pars_show” która to wczytuje funkcję “pars_file” z pliku “Data_pars” wraz z wyświetleniem napisu pod przyciskiem “Dane Zostały Przeanalizowane” jednocześnie ukrywając napisy pod pozostałymi przyciskami.

“Wyświetl Dane” wykonuje funkcję “display_show” mającą za zadanie wykonać funkcję “display_data” z pliku “Data_display”, następnie wypisuje pod przyciskiem komunikat “Dane Są Wyświetlane W Nowym Oknie” w tym samym czasie ukrywając napisy pod przyciskami powyżej.

“Usuń Dane” odnosi się do funkcji “dump_show” odpowiedzialną za uruchomienie funkcji “data_dump” w pliku “Data_Download” wraz z wyświetleniem komunikatu “Dane Zostały Usunięte” oraz ukrycie komunikatów od pozostałych przycisków.

Ostatnie dwa regiony są poświęcone przycisku do zamykania aplikacji i czyszczenia danych oraz aktywacji aplikacji.

Zamknięcie aplikacji dzieje się za pośrednictwem parametru “command” odnoszącego się do funkcji “close_app” która to niszczy proces za pomocą parametru “destroy”, a także również wykonuje funkcję “data_dump” z pliku “Data_Download” w celu wyczyszczenia danych.

Natomiast uruchomienie aplikacji dzieje się za pośrednictwem komendy “mainloop” przypisanej do głównej zmiennej “app”.

Data_download.py

Plik ten jest podzielony na trzy regiony oddzielające od siebie import bibliotek od funkcji tego pliku.

Biblioteki wykorzystane w tej części aplikacji to;

- **BeautifulSoup**
- **Requests**
- **tkinter**
- **Json**

Funkcja wykonawcza pliku nazywa się “data_scrap” i za pośrednictwem biblioteki request pobiera ona dane z strony podanej przez użytkownika. Pobrane pliki następnie są przetwarzane przez bibliotekę “BeautifulSoup” wykorzystując “html.parser”.

Następnie w pobranym kodzie HTML wyszukiwana jest najbliższy element oznaczony jako tabela, po czym z tych wierszy pobierane są wiersze oznaczone “<tr>” nagłówki oznaczone “<th>” i dane do tabeli oznaczone “<td>”. Po wyciągnięciu danych są one czyszczone z zbędnych białych znaków.

Pobrane i przetworzone dane są dodawane do listy “data” po czym otwierany jest plik “Download_data.json” do którego wpisywane są uporządkowane dane, na koniec funkcja wypisuje w terminalu informacje o udanym zapisaniu danych.

W dalszej części kodu zaimplementowana została funkcja odpowiedzialna za otwieranie nowego okna aplikacji, w którym użytkownik może podać adres strony internetowej i pobrać z niej dane. Parametry okna aplikacji zostały nadane takie same jak dla okna głównego.

W pliku znajduje się też funkcja odpowiedzialna za czyszczenie pliku JSON z zawartości poprzez wstawienie w miejsce danych pustej tablicy. Następuje to w przypadku ręcznego wywołania jej przyciskiem do tego stworzonym lub wyjścia z aplikacji za pomocą guzika w oknie głównym.

Data_pars.py

W pliku tym została zaimportowana tylko jedna biblioteka pozwalająca na odczytywanie i dostęp do pliku JSON z pobranymi danymi.

Funkcją wykonawczą tego pliku jest “pars_file” mający zaimplementowaną ścieżkę dostępu do pliku JSON zawierającego uporządkowane informacje, które następnie analizuje i układa w celu zwiększenia przejrzystości.

Program zaczyna od otworzenia i odczytania pliku danych, jednocześnie sprawdzając czy dane te mają odpowiednie kodowanie w postaci “utf-8” i w przypadku błędu formatu danych bądź ich braku zwraca wiadomość o błędzie.

Następnie kod pobiera pierwszy wiersz danych, w którym zawarte są nazwy kolumn i przypisuje go do zmiennej “headers”, po czym wykonuje to samo dla reszty wierszy, w których są powiązane dane i przypisuje je do zmiennej “data_rows”.

W kolejnym etapie tworzona jest lista słowników, w których jako klucz ustawiane są nagłówki, a jako wartości przypisywane są pozostałe dane.

Następnie z wykorzystaniem “textwrap” wypisywane są dane w terminalu układając je numerycznie tak jak były prezentowane na stronie.

Data_display.py

Plik odpowiedzialny za wyświetlanie tabeli danych w nowym oknie aplikacji. W tym celu potrzebne były biblioteki tkinter i JSON.

W kodzie jest zaimplementowana pusta zmienna `app2` która później zostanie zmieniona na zmienną globalną w celu utworzenia instrukcji warunkowej sprawdzającej czy nowe okno aplikacji już istnieje, tak by się nie podwajały. W razie wykrycia takiego okna wyświetla stosowne okno błędu “messagebox”.

Funkcją wykonawczą w tym kodzie jest “`display_data`” mająca zaimplementowaną ścieżkę pliku JSON. Poza instrukcją warunkową opisaną wyżej w kodzie znajduje się ten sam sposób weryfikacji poprawności i wczytywania danych do zmiennych jak w pliku “`Data_pars`”.

Następnie w kodzie wykorzystane są elementy pliku “`Main`” w celu utworzenia nowego okna aplikacji “`app3`” oraz nadaniu mu odpowiednich parametrów wraz z tytułem znajdującym się nad tabelą z danymi.

W końcowej części kodu za pomocą parametry “`ttk`” biblioteki “`tkinter`” jest tworzona tabela “`treeview`” danych wyświetlana w aplikacji przypisana pod zmienną “`tree`”, a także wykorzystując pętlę do ustawienia kolumn i rzędów w pożądanym sposób. Wraz z przyciskiem służącym do zamknięcia okna z tabelą.

Źródła użyte w trakcie prac nad projektem:

- <https://docs.python.org/pl/3>
- <https://docs.python.org/3/library/tk.html>
- <https://www.youtube.com/watch?v=LC9yE7T93cs>
- https://tedboy.github.io/bs4_doc
- <https://sites.google.com/view/paztronomer/blog/basic/python-colors>
- <https://stackoverflow.com>

Przykładowe strony użyte w testowaniu kodu:

- <https://www.scrapethissite.com/pages/forms/>
- https://pl.wikipedia.org/wiki/Lista_najwi%C5%9Bszych_przedsi%C4%99biorstw